

Analyse des thèmes dans les romans de Zola

Morgan RICHARD

1 Introduction

Émile Zola, l'un des écrivains majeurs du XIX^e siècle, est connu pour ses romans naturalistes, dans lesquels il explore les dimensions sociales, économiques et psychologiques de la vie humaine. Son œuvre romanesque constitue ainsi un corpus particulièrement riche pour l'analyse des thèmes récurrents, des milieux sociaux et des motifs narratifs.

Dans cette étude, nous examinons les thèmes présents dans les romans de Zola afin de déterminer dans quelle mesure certains motifs apparaissent de manière transversale dans son œuvre. Pour cela, nous mobilisons des méthodes d'analyse textuelle non supervisées, capables d'identifier des regroupements lexicaux à partir des textes eux-mêmes.

La question centrale de cette étude est donc la suivante : dans quelle mesure des méthodes non supervisées comme la NMF et K-means permettent-elles de faire apparaître des structures thématiques récurrentes dans l'œuvre romanesque de Zola ?

L'objectif est de vérifier si les regroupements produits automatiquement correspondent à des motifs interprétables dans le cadre d'une analyse littéraire. Il ne s'agit donc pas de remplacer la lecture critique des textes, mais d'utiliser les outils du traitement automatique du langage comme un moyen d'explorer un corpus littéraire volumineux.

Ce travail constitue le premier volet d'une série d'analyses portant sur des corpus de textes littéraires issus d'auteurs naturalistes et non naturalistes. Il sert à la fois de cas d'étude méthodologique et de base pour de futures comparaisons entre différents ensembles d'œuvres.

Deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola :

- la NMF (Non-negative Matrix Factorization) ¹ : une technique de réduction de dimensionnalité qui permet d'extraire des topics à partir d'un corpus de textes ;
- K-means : une méthode de clustering qui permet de regrouper les segments textuels en fonction de leur proximité lexicale.

Ces méthodes seront expliquées dans les sections suivantes, avant la présentation des résultats de l'analyse thématique des romans de Zola.

1. N. Gillis, *Nonnegative Matrix Factorization*, Society for Industrial and Applied Mathematics, coll. « Data Science », 2020.

2 Présentation du corpus

Comme indiqué en introduction, cette étude porte sur un corpus composé exclusivement de romans d'Émile Zola. Le choix a été fait de ne pas inclure les nouvelles, les textes journalistiques ni les essais, afin de conserver un ensemble relativement homogène du point de vue générique. Les romans offrent en effet une matière textuelle plus longue et plus développée, ce qui permet d'observer plus finement les thèmes récurrents, les milieux sociaux et les motifs narratifs présents dans l'œuvre de Zola.

L'exclusion des nouvelles répond également à une contrainte méthodologique. Ces textes sont généralement plus courts que les romans et leur intégration aurait pu créer un déséquilibre dans le corpus. Dans le cadre d'une analyse thématique fondée sur des segments textuels, les différences importantes de longueur entre les œuvres peuvent influencer la représentation des thèmes. Limiter le corpus aux romans permet donc de réduire cet effet et de travailler sur un ensemble plus comparable.

Le corpus comprend les œuvres suivantes :

TABLE 1: Corpus des œuvres de Zola utilisées dans l'analyse

Date	Titre	Fichier
1865	<i>La confession de Claude</i>	1865_La_confession_de_Claude._clean.txt
1866	<i>Le vœu d'une morte</i>	1866_Le_voeu_d_une_morte._clean.txt
1867	<i>Les mystères de Marseille</i>	1867_Les_mysteres_de_Marseille._clean.txt
1867	<i>Thérèse Raquin</i>	1867_Therese_Raquin._clean.txt
1868	<i>Madeleine Férat</i>	1868_Madeleine_Ferat._clean.txt
1871	<i>La fortune des Rougon</i>	1871_1_La_fortune_des_Rougon._clean.txt
1872	<i>La curée</i>	1871_2_La_curee._clean.txt
1873	<i>Le ventre de Paris</i>	1873_3_Le_ventre_de_Paris._clean.txt
1874	<i>La conquête de Plassans</i>	1874_4_La_conquete_de_Plassans._clean.txt
1875	<i>La faute de l'abbé Mouret</i>	1875_5_La_faute_de_l_abbe_Mouret._clean.txt
1876	<i>Son Excellence Eugène Rougon</i>	1876_6_Son_Excellence_Eugene_Rougon._clean.txt
1877	<i>L'assommoir</i>	1877_7_L_assommoir._clean.txt
1878	<i>Une page d'amour</i>	1878_8_Une_page_d_amour._clean.txt
1880	<i>Nana</i>	1880_9_Nana._clean.txt
1882	<i>Pot-Bouille</i>	1882_10_Pot-bouille._clean.txt
1883	<i>Au Bonheur des dames</i>	1883_11_Au_Bonheur_des_dames._clean.txt
1884	<i>La joie de vivre</i>	1884_12_La_joye_de_vivre._clean.txt
1885	<i>Germinal</i>	1885_13_Germinal._clean.txt
1886	<i>L'œuvre</i>	1886_14_L_oeuvre._clean.txt
1887	<i>La terre</i>	1887_15_La_terre._clean.txt
1888	<i>Le rêve</i>	1888_16_Le_reve._clean.txt
1890	<i>La bête humaine</i>	1890_17_La_bete_humaine._clean.txt
1891	<i>L'argent</i>	1891_18_L_argent._clean.txt

Date	Titre	Fichier
1892	<i>La débâcle</i>	1892_19_La_debacle._clean.txt
1893	<i>Le docteur Pascal</i>	1893_20_Le_docteur_Pascal._clean.txt
1894	<i>Lourdes</i>	1894_1_Lourdes._clean.txt
1896	<i>Rome</i>	1896_2_Rome._clean.txt
1898	<i>Paris</i>	1898_3_Paris._clean.txt
1899	<i>Fécondité</i>	1899_1_Fecondite._clean.txt
1901	<i>Travail</i>	1901_2_Travail._clean.txt
1903	<i>Vérité</i>	1903_3_Verite._clean.txt

Le corpus est composé de 31 romans, qui couvrent les principales périodes de la production romanesque de Zola. Il comprend :

- 5 romans antérieurs au cycle des *Rougon-Macquart* ;
- 20 romans appartenant au cycle des *Rougon-Macquart* ;
- 3 romans du cycle des *Trois Villes* ;
- 3 romans publiés du cycle des *Quatre Évangiles*.

Pour ce qui est des *Quatre Évangiles*, *Vérité* paraît à titre posthume. *Justice* ne paraîtra jamais, l’ouvrage étant resté à l’état d’ébauche au moment de la mort de l’écrivain.

Ce corpus permet donc de couvrir une large période de la carrière de Zola, depuis ses premiers romans jusqu’à ses dernières œuvres. Cette amplitude chronologique est importante pour l’analyse, car elle permet d’observer non seulement les thèmes récurrents de l’œuvre romanesque, mais aussi leur possible évolution au fil du temps².

3 Méthodologie de préparation des données

Dans cette étude, le terme *topic* désigne un regroupement lexical produit par le modèle NMF, tandis que le terme *cluster* désigne un groupe de segments obtenu par K-means. Le terme *thème* est réservé à l’interprétation qualitative de ces regroupements. Cette précision terminologique est importante pour éviter toute confusion entre les différentes étapes de l’analyse.

3.1 Préparation des données brutes en données propres

Les romans au format `.txt` correspondent à des versions nettoyées, c’est-à-dire à des textes dont les éléments non textuels ont été supprimés. Ces éléments comprennent notamment les titres, les chapitres, les notes de bas de page et d’autres informations éditoriales qui pourraient perturber l’analyse. Ce nettoyage permet d’obtenir une représentation plus précise des thèmes présents dans les romans.

². En vue d’une éventuelle analyse ultérieure par dynamic topic modeling sur ce même corpus.

De plus, le choix a été fait de conserver une seule phrase par ligne. Ce format facilite l’analyse textuelle, notamment pour les méthodes de la NMF et de K-means, qui nécessitent une structure de données homogène pour fonctionner correctement.

Cette logique de formatage a également été appliquée en prévision des analyses futures. Les romans issus de prochains traitements pourront ainsi être intégrés de manière cohérente au corpus. Ce choix permet de limiter les différences de structure entre les fichiers et d’obtenir un format homogène pour l’analyse sans trop complexifier le processus de préparation des données.

TABLE 2: Nombre de tokens par roman dans l’ordre chronologique

Titre du roman	Nombre de tokens
<i>La confession de Claude</i>	47253
<i>Le vœu d’une morte</i>	38722
<i>Les mystères de Marseille</i>	125253
<i>Thérèse Raquin</i>	66363
<i>Madeleine Féral</i>	97318
<i>La fortune des Rougon</i>	116685
<i>La curée</i>	105120
<i>Le ventre de Paris</i>	110442
<i>La conquête de Plassans</i>	113245
<i>La faute de l’abbé Mouret</i>	114667
<i>Son Excellence Eugène Rougon</i>	126186
<i>L’assommoir</i>	158340
<i>Une page d’amour</i>	102185
<i>Nana</i>	141573
<i>Pot-Bouille</i>	134844
<i>Au Bonheur des dames</i>	147521
<i>La joie de vivre</i>	117255
<i>Germinal</i>	164473
<i>L’œuvre</i>	130613
<i>La terre</i>	163687
<i>Le rêve</i>	66379
<i>La bête humaine</i>	125418
<i>L’argent</i>	143010
<i>La débâcle</i>	187046
<i>Le docteur Pascal</i>	112713
<i>Lourdes</i>	173511
<i>Rome</i>	233958
<i>Paris</i>	177389
<i>Fécondité</i>	220131
<i>Travail</i>	198712
<i>Vérité</i>	223274

Le tableau fournit une description quantitative du corpus en indiquant, pour chaque roman, le nombre de tokens obtenus après nettoyage. Les œuvres sont présentées dans l'ordre chronologique, ce qui permet d'observer l'évolution du volume textuel au sein de la production romanesque de Zola. Les écarts sont importants entre les romans courts du début de carrière, comme *Le vœu d'une morte*, et les œuvres plus volumineuses de la fin de carrière, notamment *Rome, Fécondité, Travail* et *Vérité*.

Cette information est importante pour l'interprétation des résultats, car la longueur des textes peut avoir un effet sur la représentation des thèmes. Un roman plus long fournit mécaniquement davantage d'occurrences lexicales et davantage de segments analysables. La segmentation en paquets de phrases vise donc à produire des unités d'analyse plus comparables, tout en conservant suffisamment de contexte pour identifier les thèmes dominants.

3.2 Préparation du corpus pour l'analyse thématique

Pour préparer le corpus à l'analyse thématique, nous avons adopté une procédure visant à produire des unités textuelles comparables et exploitables par les modèles.

Les romans ont été segmentés en paquets de phrases³. Chaque paquet est composé de 40 phrases. Cette taille a été retenue car elle offre un compromis entre deux exigences : conserver suffisamment de contexte pour identifier les thèmes présents dans les romans, tout en permettant une analyse plus fine qu'un découpage à l'échelle du chapitre ou de l'œuvre entière.

Ce choix reste toutefois méthodologique et partiellement arbitraire. Plusieurs tailles de paquets ont été testées⁴. Les paquets de 40 phrases ont été retenus, car ils produisaient les résultats les plus cohérents et les plus interprétables parmi les configurations testées. Ce choix n'est donc pas parfait, mais il constitue le meilleur compromis observé dans le cadre de cette analyse.

D'autres modes de segmentation ont également été envisagés, notamment un découpage par chapitre ou par paragraphe. Le découpage par chapitre a été écarté, car les chapitres ne constituent pas des unités suffisamment homogènes en longueur et en contenu. Certains chapitres sont très courts, tandis que d'autres sont beaucoup plus longs, ce qui rend la comparaison entre unités d'analyse plus difficile.

Le découpage par paragraphe a également été étudié, mais il posait plusieurs problèmes. D'abord, les paragraphes varient fortement en longueur : certains sont très courts, tandis que d'autres sont beaucoup plus développés. Cette difficulté pourrait être partiellement corrigée par un filtrage des paragraphes trop courts ou trop longs, mais cela introduirait une étape supplémentaire et rendrait le traitement moins homogène.

Ensuite, l'architecture matérielle des textes n'est pas toujours conservée de manière fiable dans les fichiers disponibles. Certains romans ne présentent plus

3. Le code pour segmenter les romans est disponible en annexe, dans la section « Segmentation du corpus ».

4. Différents essais ont été réalisés avec des paquets de 10, 50, 70 et 100 phrases.

une mise en page avec des paragraphes clairement identifiables, en particulier lorsque les textes proviennent de formats différents, comme des fichiers `.txt`, `.pdf` ou `.epub`. Or, ce travail s'inscrit dans une perspective d'élargissement du corpus à d'autres romans et à d'autres sources textuelles. Dans ce contexte, la segmentation par phrase apparaît plus facilement généralisable à des formats hétérogènes.

Enfin, la structure interne des romans pose un dernier problème. Les dialogues peuvent être considérés comme des paragraphes indépendants, ce qui produit parfois des unités d'analyse très courtes, composées de seulement quelques mots. Là encore, un filtrage serait possible, mais il complexifierait le protocole et risquerait d'introduire des différences de traitement entre les textes.

Pour ces raisons, le découpage en paquets de 40 phrases a été retenu. Il permet de produire des unités d'analyse relativement homogènes, applicables à l'ensemble du corpus, tout en conservant une quantité suffisante de contexte pour l'analyse thématique.

3.3 Statistiques descriptives du corpus

TABLE 3: Nombre de paquets de phrases par roman

Titre du roman	Nombre de paquets
<i>La confession de Claude</i>	65
<i>Le vœu d'une morte</i>	60
<i>Les mystères de Marseille</i>	184
<i>Thérèse Raquin</i>	80
<i>Madeleine Féral</i>	124
<i>La fortune des Rougon</i>	154
<i>La curée</i>	123
<i>Le ventre de Paris</i>	136
<i>La conquête de Plassans</i>	165
<i>La faute de l'abbé Mouret</i>	171
<i>Son Excellence Eugène Rougon</i>	191
<i>L'assommoir</i>	228
<i>Une page d'amour</i>	166
<i>Nana</i>	225
<i>Pot-Bouille</i>	207
<i>Au Bonheur des dames</i>	198
<i>La joie de vivre</i>	164
<i>Germinal</i>	225
<i>L'œuvre</i>	163
<i>La terre</i>	222
<i>Le rêve</i>	82
<i>La bête humaine</i>	154
<i>L'argent</i>	155
<i>La débâcle</i>	221
<i>Le docteur Pascal</i>	135
<i>Lourdes</i>	198
<i>Rome</i>	231
<i>Paris</i>	206
<i>Fécondité</i>	259
<i>Travail</i>	208
<i>Vérité</i>	227

Ce tableau indique le nombre de paquets de phrases obtenus pour chaque roman après segmentation du corpus. Les écarts observés reflètent principalement les différences de longueur entre les œuvres : les textes les plus courts, comme *Le vœu d'une morte* ou *La confession de Claude*, produisent peu de paquets, tandis que les romans plus volumineux, comme *Fécondité*, *Rome* ou *L'assommoir*, en produisent davantage.

3.3.1 Analyse des statistiques descriptives du nombre de paquets par roman

TABLE 4 – Statistiques descriptives du nombre de paquets par roman

Indicateur	Valeur
Nombre de romans	31
Moyenne	171.84
Écart-type	52.40
Minimum	60
Premier quartile	145
Médiane	171
Troisième quartile	214.5
Maximum	259

Les statistiques descriptives du nombre de paquets par roman permettent d'évaluer la structure quantitative du corpus après segmentation. Le corpus comprend 31 romans, avec une moyenne d'environ 172 paquets de phrases par œuvre. La médiane, située à 171 paquets, est très proche de cette moyenne. Cette proximité indique que la distribution générale du nombre de paquets n'est pas fortement asymétrique : la majorité des romans se situe autour d'un volume intermédiaire, même si certains textes s'écartent nettement de cette tendance.

L'écart-type, d'environ 52 paquets, montre toutefois une dispersion importante autour de la moyenne. Cette variation s'explique principalement par les différences de longueur entre les romans. Les œuvres les plus courtes, comme *Le vœu d'une morte*, produisent seulement 60 paquets, tandis que les textes les plus longs, comme *Fécondité*, atteignent 259 paquets. L'écart entre le minimum et le maximum est donc notable, puisqu'il existe presque un rapport de un à quatre entre le roman le moins segmenté et le roman le plus segmenté.

Les quartiles permettent de préciser cette répartition. Le premier quartile, situé à 145 paquets, indique qu'un quart des romans contient 145 paquets ou moins. Le troisième quartile, situé à 214,5 paquets, indique qu'environ trois quarts des romans restent sous ce seuil. La moitié centrale du corpus se situe donc entre 145 et 214,5 paquets, ce qui montre que la majorité des œuvres conserve une taille relativement comparable après segmentation. Les valeurs extrêmes ne remettent donc pas en cause l'homogénéité générale du corpus, mais elles doivent être prises en compte dans l'interprétation des résultats.

Le coefficient de variation est d'environ 30 %, puisqu'il correspond au rapport entre l'écart-type et la moyenne. Cette valeur signale une variabilité modérée : les romans ne sont pas tous de taille équivalente, mais les écarts restent attendus pour un corpus littéraire composé d'œuvres publiées à des périodes différentes et appartenant à plusieurs cycles romanesques. Cette dispersion est donc méthodologiquement acceptable, à condition de garder à l'esprit que les romans les plus longs fournissent davantage d'unités d'analyse.

Cette information est importante pour l’analyse thématique. Chaque paquet de phrases constitue une unité soumise aux méthodes de topic modeling. Par conséquent, un roman plus long contribue mécaniquement à un plus grand nombre d’observations qu’un roman court. Les thèmes présents dans les romans volumineux peuvent donc être davantage représentés dans les résultats globaux. La segmentation en paquets de 40 phrases permet néanmoins de réduire cet effet, car elle transforme les romans en unités textuelles comparables tout en conservant suffisamment de contexte pour identifier des thèmes cohérents.

Ainsi, ces statistiques montrent que le corpus présente un équilibre satisfaisant pour une analyse thématique. Les différences de taille entre les romans existent, mais elles sont documentées et peuvent être intégrées à l’interprétation des résultats. Cette étape descriptive permet donc de mieux contrôler les effets liés à la longueur des œuvres avant l’application des méthodes de NMF et de K-means.

3.3.2 Analyse des statistiques descriptives du nombre de mots par paquet

TABLE 5 – Statistiques descriptives du nombre de mots par paquet

Indicateur	Valeur
Nombre de paquets	5327
Moyenne	785.30
Écart-type	212.13
Minimum	42
Premier quartile	636
Médiane	753
Troisième quartile	902.5
Maximum	2944

Les statistiques descriptives du nombre de mots par paquet permettent d’évaluer la taille effective des unités textuelles utilisées pour l’analyse thématique. Le corpus segmenté comprend 5327 paquets, avec une moyenne d’environ 785 mots par paquet. La médiane, située à 753 mots, est relativement proche de cette moyenne, ce qui indique que la majorité des paquets se situe autour d’un volume textuel comparable.

L’écart-type est d’environ 212 mots, ce qui traduit une dispersion modérée autour de la moyenne. Le coefficient de variation est d’environ 27 %, puisqu’il correspond au rapport entre l’écart-type et la moyenne. Cette valeur indique que les paquets ne sont pas parfaitement homogènes en longueur, mais que la variabilité reste acceptable pour une analyse thématique. Cette variation s’explique par le fait que les paquets sont construits à partir d’un nombre fixe de phrases, et non d’un nombre fixe de mots : selon le style, le rythme narratif ou la longueur syntaxique des phrases, deux paquets de 40 phrases peuvent contenir

un nombre de mots assez différent.

Les quartiles permettent de préciser cette distribution. Un quart des paquets contient au maximum 636 mots, tandis que la moitié des paquets contient au maximum 753 mots. Le troisième quartile, situé à 902,5 mots, indique que 75 % des paquets ne dépassent pas environ 903 mots. Ainsi, la majorité des unités d’analyse se concentre dans une zone relativement stable, comprise approximativement entre 636 et 903 mots pour la moitié centrale du corpus. Cette concentration est favorable au topic modeling, car elle limite les écarts de taille entre les unités comparées.

Les valeurs extrêmes doivent toutefois être prises en compte. Le paquet le plus court contient seulement 42 mots, tandis que le plus long atteint 2944 mots. Ces deux valeurs indiquent la présence d’unités atypiques. Le paquet de 42 mots correspond probablement à une fin de roman ou à un segment résiduel composé de moins de phrases que les autres. À l’inverse, le paquet de 2944 mots peut provenir d’un passage composé de phrases particulièrement longues ou d’une segmentation imparfaite du texte source. Ces cas extrêmes peuvent influencer l’analyse, car un paquet très long contient davantage d’information lexicale et peut donc peser plus fortement dans la représentation des thèmes.

Dans l’ensemble, ces statistiques montrent que la segmentation en paquets de 40 phrases produit des unités textuelles globalement comparables. Malgré une variabilité réelle, la distribution reste suffisamment concentrée autour de la médiane pour permettre une analyse thématique cohérente. Il serait toutefois pertinent d’examiner les paquets extrêmes afin de vérifier s’ils correspondent à des cas normaux du corpus ou à des problèmes de segmentation.

3.4 Lemmatisation du corpus de Zola

Après avoir obtenu un corpus segmenté en paquets de phrases et relativement homogène en termes de nombre de mots, l’étape suivante de préparation des données a consisté à effectuer une lemmatisation du corpus⁵.

Pour réaliser cette lemmatisation, nous avons utilisé la bibliothèque `spaCy` en Python, qui offre des outils performants pour le traitement automatique du langage. La lemmatisation permet de regrouper les différentes formes d’un même mot sous une seule forme de base : par exemple, les mots « manger », « mange » et « manges » sont tous réduits au lemme « manger ». Cette étape facilite l’identification des thèmes et contribue à réduire la dimensionnalité du corpus.

Comme pour la segmentation en paquets de phrases, plusieurs essais ont été réalisés avec la bibliothèque de lemmatisation `spaCy`.

Nous avons choisi d’utiliser le modèle `fr_core_news_lg` de `spaCy`, qui est un modèle de langue française de grande taille. Ce choix a été motivé par la richesse lexicale et la complexité syntaxique des romans de Zola, qui nécessitent un modèle capable de gérer une grande variété de formes linguistiques. Le modèle `fr_core_news_lg` a été retenu, car il offre une lemmatisation plus précise que des modèles plus légers⁶, ce qui est important pour l’identification des thèmes

5. Code disponible en annexe, dans la section « Lemmatisation et filtrage lexical ».

6. Les modèles `fr_core_news_sm` et `fr_core_news_md` ont également été envisagés.

dans les textes littéraires.

Une liste de mots à exclure a été construite progressivement au cours de plusieurs itérations de prétraitement⁷. Elle résulte de l’observation conjointe des sorties de lemmatisation et de la matrice terme-document. L’objectif était d’identifier les formes lexicales très fréquentes dans le corpus, mais peu discriminantes pour l’analyse thématique.

Cette liste contient d’abord des mots-outils, tels que les pronoms personnels, les conjonctions, les déterminants et les prépositions. Ces termes structurent grammaticalement les phrases, mais ils ne permettent pas d’identifier les thèmes dominants des romans. Leur présence importante dans la matrice terme-document risquait donc de réduire la lisibilité des topics produits par la NMF.

La liste a également été enrichie par l’ajout de certains noms propres, notamment des noms de personnages récurrents dans les romans de Zola. Ces noms apparaissent fréquemment dans les textes, mais leur poids lexical tendait à orienter les topics vers des personnages plutôt que vers des thèmes plus généraux, comme le travail, la famille, la religion, l’argent ou les rapports sociaux. Leur exclusion permet donc de privilégier une interprétation thématique plutôt qu’une simple identification des protagonistes.

Ce filtrage relève d’un choix méthodologique empirique. Lors des premiers essais, plusieurs mots restaient fortement représentés dans les résultats malgré les paramètres appliqués au lemmatiseur et au vectoriseur. La liste d’exclusion a donc été ajustée à partir de l’examen des termes les plus fréquents et des premiers topics obtenus. Elle vise à améliorer la qualité interprétative de la matrice terme-document en conservant prioritairement les mots porteurs d’information thématique.

Une fonction applique le modèle `spaCy` à chaque segment du corpus afin d’en extraire une version lemmatisée et filtrée⁸. Pour chaque token, le lemme est d’abord converti en minuscules afin de normaliser les formes lexicales. La fonction exclut ensuite les mots vides, la ponctuation, les nombres, les espaces, ainsi que les lemmes trop courts ou présents dans la liste personnalisée de mots à retirer. Le filtrage conserve uniquement les noms et les adjectifs, car ces catégories grammaticales sont généralement les plus porteuses d’information thématique dans le cadre d’une analyse de topics. Le résultat final est une chaîne de caractères composée des lemmes retenus, qui peut ensuite être utilisée pour construire la matrice terme-document.

À l’issue de cette préparation, chaque roman est représenté par un ensemble de segments lemmatisés et filtrés. Ces segments constituent les unités d’analyse utilisées pour les deux méthodes de modélisation thématique présentées dans la section suivante.

7. Elle est présente en annexe du document.

8. Fonction en Python disponible en annexe du document.

4 Analyse avec la NMF et K-means

Comme mentionné précédemment, deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola : la NMF (Non-negative Matrix Factorization) et K-means. Cette section présente ces deux méthodes et expose les choix retenus pour leur application au corpus préparé.

4.1 La méthode NMF

La NMF est une technique de réduction de dimensionnalité qui permet d'extraire des thèmes à partir d'un corpus de textes. Elle fonctionne en factorisant la matrice terme-document en deux matrices non négatives : une matrice de thèmes et une matrice de poids. La matrice de thèmes contient les mots les plus représentatifs de chaque thème, tandis que la matrice de poids indique l'importance de chaque thème dans chaque document ou paquet de phrases.

La présentation commence par la NMF, avant d'aborder le clustering par K-means comme méthode complémentaire.

Après la préparation du corpus, la segmentation en paquets de phrases et la lemmatisation des textes, l'étape suivante consiste à appliquer une méthode de modélisation thématique. L'objectif est d'identifier automatiquement les grands thèmes présents dans les romans de Zola, à partir des termes les plus représentatifs de chaque segment textuel.

Dans cette analyse, la méthode retenue est la NMF, pour *Non-negative Matrix Factorization*. Cette méthode permet de décomposer une matrice terme-document en deux matrices plus simples : une matrice associant les segments de texte aux topics, et une matrice associant les topics aux termes les plus caractéristiques. La NMF est particulièrement adaptée à ce type d'analyse, car elle produit des résultats relativement interprétables : chaque topic peut être compris comme un ensemble de mots fortement associés entre eux.

4.1.1 Création de la matrice terme-document

La première étape consiste à transformer les textes lemmatisés en une représentation numérique exploitable par le modèle. Pour cela, une matrice terme-document a été construite à l'aide d'une pondération TF-IDF⁹. Cette méthode permet de donner un poids plus important aux termes caractéristiques d'un segment, tout en réduisant l'influence des mots trop fréquents dans l'ensemble du corpus.

Les paramètres `min_df` et `max_df` jouent un rôle important dans la qualité de la matrice obtenue. Le paramètre `min_df=3` permet d'exclure les mots qui apparaissent dans moins de trois segments. Ces mots sont généralement trop rares pour contribuer efficacement à l'identification de thèmes récurrents. À l'inverse, le paramètre `max_df=0.8` exclut les termes présents dans plus de 80 % des segments, car ils sont trop fréquents pour être réellement discriminants¹⁰.

9. Utilisée via la bibliothèque `scikit-learn`.

10. Le vectoriseur est disponible en annexe.

Ce choix relève d'un arbitrage méthodologique. Plusieurs combinaisons ont été testées, puis évaluées à partir de la qualité des mots conservés et de la cohérence des premiers topics obtenus. L'objectif n'était donc pas seulement de réduire la taille de la matrice, mais surtout de conserver les termes les plus utiles pour l'analyse thématique. La matrice finale sert ensuite de base à l'application du modèle NMF.

4.1.2 Choix du nombre de topics

Le choix du nombre de topics constitue une étape importante dans une analyse par NMF. Un nombre trop faible de topics risque de produire des catégories trop générales, dans lesquelles plusieurs thèmes distincts se trouvent regroupés. À l'inverse, un nombre trop élevé peut conduire à une fragmentation excessive des résultats, avec des topics trop proches les uns des autres ou difficiles à interpréter.

Afin d'orienter ce choix, une méthode du coude a d'abord été utilisée¹¹. Cette méthode consiste à entraîner plusieurs modèles NMF avec différents nombres de topics, puis à observer l'évolution de l'erreur de reconstruction. L'objectif est d'identifier un éventuel seuil à partir duquel l'ajout de nouveaux topics n'améliore plus fortement la qualité de reconstruction du modèle.




FIGURE 1 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 2 et 40 topics

La première visualisation présente l'évolution de l'erreur de reconstruction pour un nombre de topics compris entre 2 et 40. On observe une diminution régulière de l'erreur lorsque le nombre de topics augmente. Cette baisse est attendue : plus le modèle dispose de topics, plus il peut reconstruire finement

11. Code visible en annexe.

la matrice terme-document. Cependant, la courbe ne présente pas de rupture nette permettant d'identifier un coude évident. Le critère quantitatif ne suffit donc pas, à lui seul, à déterminer un nombre optimal de topics.

Une seconde visualisation a été produite en resserrant l'observation sur une zone plus restreinte, comprise entre 20 et 39 topics. Ce zoom permet d'examiner plus précisément la partie de la courbe dans laquelle plusieurs valeurs candidates pouvaient être envisagées.




FIGURE 2 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 20 et 39 topics

Ce second graphique confirme l'absence de seuil clairement marqué. L'erreur de reconstruction continue de diminuer de manière progressive, sans stabilisation brutale ni changement de pente suffisamment net pour imposer une valeur unique. Le choix du nombre de topics ne peut donc pas reposer uniquement sur la méthode du coude.

Le choix final a ainsi été complété par une analyse qualitative des résultats. Plusieurs valeurs ont été testées, notamment 10, 15, 20, 30 et 35 topics. Les modèles obtenus ont été comparés à partir des mots caractéristiques de chaque topic, de leur cohérence interne et de leur capacité à correspondre à des thèmes interprétables dans l'œuvre de Zola. Dans cette perspective, le choix de 29 topics a été retenu comme un compromis entre précision, lisibilité et stabilité interprétative.

Ce choix a également été mis en relation avec l'analyse par K-means. Le nombre de clusters retenu pour K-means a été fixé à 29 afin de permettre une comparaison directe entre les deux méthodes. Cette seconde approche ne sert pas à prouver définitivement que 29 est le nombre optimal de topics, mais elle permet de vérifier si une structuration thématique comparable apparaît lorsque les segments sont regroupés selon une logique différente. Autrement dit, K-means

joue ici un rôle de validation complémentaire : si certains motifs apparaissent à la fois dans les topics NMF et dans les clusters K-means, cela renforce leur pertinence pour l'analyse du corpus.

4.1.3 Paramétrage du modèle NMF

Après plusieurs essais, le modèle final a été construit avec 29 topics. Cette valeur a été retenue, car elle permettait d'obtenir un niveau de détail suffisant, sans produire une fragmentation trop importante des thèmes ni introduire trop de bruit. Les topics obtenus correspondent à des ensembles thématiques distincts, comme le monde ouvrier, la religion, la famille, la finance, la guerre, le commerce, la médecine ou encore l'espace domestique, comme nous le verrons dans la section consacrée aux résultats.

Le paramètre `n_components=29` correspond au nombre de topics recherchés. Le paramètre `random_state=42` permet d'assurer la reproductibilité des résultats. L'initialisation `nndsvda`¹² est adaptée à la NMF, car elle fournit une initialisation stable à partir de la structure de la matrice. Le solveur `cd`, pour *coordinate descent*, est utilisé pour optimiser la factorisation.

La matrice W contient les poids des topics pour chaque segment du corpus. Autrement dit, elle indique dans quelle mesure chaque segment est associé à chacun des 29 topics. La matrice H , quant à elle, contient les poids des mots pour chaque topic. Elle permet donc d'identifier les termes les plus représentatifs de chaque thème.

4.1.4 Limites de l'approche

L'utilisation de la NMF présente plusieurs avantages, notamment sa lisibilité et sa capacité à produire des topics relativement interprétables. Cependant, cette méthode comporte aussi des limites. Le choix du nombre de topics reste en partie subjectif, surtout lorsque la méthode du coude ne permet pas d'identifier une valeur optimale claire. Dans cette analyse, le choix de 29 topics repose donc sur un compromis entre précision, lisibilité et cohérence interprétative. La validation humaine des résultats est donc essentielle pour s'assurer que les topics produits correspondent à des thèmes réels et pertinents dans l'œuvre de Zola.

De plus, les noms attribués aux topics résultent d'une interprétation humaine. Deux personnes pourraient parfois proposer des intitulés légèrement différents pour un même groupe de mots. Il est donc important de considérer ces noms comme des outils d'analyse, et non comme des catégories fixes ou définitives. Cette subjectivité ne remet pas en cause la validité de l'analyse, mais elle souligne l'importance d'une approche critique et réflexive dans l'interprétation des résultats.

Enfin, les résultats dépendent fortement des choix effectués en amont : nettoyage du texte, lemmatisation, liste de mots à exclure, taille des segments, paramètres du vectoriseur et nombre de topics. La modélisation thématique

12. L'initialisation `nndsvda` correspond à une variante de NNDSDV dans laquelle les zéros sont remplacés par la moyenne de la matrice. Voir la documentation de `scikit-learn`.

ne doit donc pas être comprise comme une méthode entièrement automatique, mais comme un processus exploratoire qui combine traitement statistique et interprétation qualitative avec validation humaine à chaque étape.

4.1.5 Bilan méthodologique

Cette étape de modélisation par NMF permet d'obtenir une première cartographie thématique du corpus romanesque de Zola. Elle fournit une base quantitative pour observer des régularités lexicales qui seront ensuite interprétées dans la section consacrée aux résultats.

La NMF constitue donc un outil pertinent pour explorer les thèmes récurrents dans un corpus littéraire volumineux. Elle ne remplace pas l'analyse littéraire, mais elle permet de faire apparaître des régularités lexicales et thématiques qui peuvent ensuite être interprétées plus finement. Dans le cadre de cette étude, elle sert à établir une base quantitative pour l'analyse des thèmes présents dans les romans de Zola.

4.2 La méthode K-means

Après l'application de la NMF, une seconde méthode a été utilisée afin de compléter l'analyse thématique du corpus : le clustering par K-means. Contrairement à la NMF, qui cherche à décomposer la matrice terme-document en topics latents, K-means vise à regrouper les segments textuels en ensembles homogènes à partir de leur proximité lexicale. L'objectif n'est donc pas exactement le même : la NMF permet d'identifier des thèmes sous forme de combinaisons de mots, tandis que K-means permet de regrouper les paquets de phrases qui présentent des profils lexicaux similaires.

Cette seconde méthode a été utilisée comme un outil complémentaire de comparaison et de validation. Elle permet de vérifier si les regroupements produits par la NMF correspondent également à des ensembles cohérents lorsque l'on applique une méthode de clustering non supervisée. Dans le cadre de cette analyse, chaque paquet de phrases constitue une unité d'observation, représentée numériquement par une matrice TF-IDF. Les clusters obtenus correspondent donc à des groupes de segments partageant des termes caractéristiques.

4.2.1 Préparation de la matrice TF-IDF

Comme pour la NMF, la première étape consiste à transformer les textes lemmatisés en une représentation numérique. La matrice utilisée pour le K-means est construite à partir des segments lemmatisés du corpus. Le même type de vectorisation TF-IDF et les mêmes paramètres ont été conservés afin d'assurer une cohérence méthodologique entre les deux approches¹³.

Ce choix permet de travailler sur une matrice plus lisible et plus pertinente pour le clustering. Le but n'est pas seulement de réduire le nombre de dimen-

13. Voir la section consacrée à la préparation de la matrice terme-document dans l'approche NMF.

sions, mais aussi de conserver les mots qui participent réellement à la différenciation des segments. Cette étape est essentielle, car la qualité des clusters dépend directement de la qualité de la représentation vectorielle utilisée.

4.2.2 Recherche du nombre de clusters

Le choix du nombre de clusters est une étape centrale dans l'utilisation de K-means. Un nombre trop faible de clusters risque de produire des groupes trop généraux, dans lesquels plusieurs thèmes différents seraient mélangés. À l'inverse, un nombre trop élevé peut produire des groupes trop fragmentés, difficiles à interpréter ou très proches les uns des autres.

Afin d'orienter ce choix, plusieurs valeurs de k ont été testées. Pour chaque valeur comprise entre 2 et 40, un modèle K-means a été entraîné, puis évalué à l'aide du score de silhouette¹⁴.

Ce score mesure la qualité de la séparation entre les clusters : plus il est élevé, plus les segments sont proches des éléments de leur propre cluster et éloignés des autres groupes.

Une visualisation des scores de silhouette a ensuite été produite afin d'observer l'évolution de la qualité du clustering selon le nombre de clusters.




FIGURE 3 – Évolution du score de silhouette en fonction du nombre de clusters dans K-means

Dans cette analyse, le score de silhouette fournit une indication quantitative, mais il ne suffit pas à lui seul à déterminer le nombre de clusters à retenir. Comme pour la NMF, le choix final repose donc sur un compromis entre indicateurs statistiques, lisibilité des résultats et cohérence interprétative. Le nombre

14. Peter J. Rousseeuw, « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis », *Journal of Computational and Applied Mathematics*, vol. 20, 1er novembre 1987, p. 53–65.

de 29 clusters a été retenu afin de permettre une comparaison directe avec les 29 topics issus de la NMF, tout en conservant un niveau de détail suffisant pour distinguer les principaux motifs thématiques du corpus. De plus, le score de silhouette reste relativement stable autour de cette valeur, ce qui indique que les clusters obtenus sont globalement cohérents.

4.2.3 Entraînement du modèle K-means

Le modèle K-means final a été entraîné avec 29 clusters. Le paramètre `random_state=42` permet d’assurer la reproductibilité des résultats, tandis que le paramètre `n_init=10` indique que l’algorithme est lancé plusieurs fois avec des initialisations différentes afin de retenir la meilleure solution.

Chaque segment du corpus reçoit ainsi un numéro de cluster après l’entraînement du modèle. L’ajout de + 1 permet de numérotter les clusters à partir de 1 plutôt qu’à partir de 0, ce qui rend les résultats plus lisibles dans les tableaux et les visualisations. Chaque paquet de phrases est donc associé à un groupe thématique déterminé par sa proximité avec les autres segments du corpus.

4.2.4 Limites de l’approche par K-means

L’utilisation de K-means présente plusieurs limites qu’il faut prendre en compte. Tout d’abord, la méthode impose une appartenance unique de chaque segment à un cluster. Or, dans un texte littéraire, un même passage peut contenir plusieurs thèmes simultanément. Un segment peut par exemple associer la famille, l’argent et la souffrance sociale, mais K-means l’attribue malgré tout à un seul groupe. Cette contrainte rend la méthode moins souple que la NMF pour représenter la complexité thématique des textes.

Ensuite, le choix du nombre de clusters reste en partie subjectif. Le score de silhouette fournit une indication utile, mais il ne suffit pas toujours à identifier une valeur optimale. Dans cette analyse, le choix de 29 clusters repose donc sur un arbitrage méthodologique : il permet de conserver un niveau de détail comparable à celui de la NMF, tout en produisant des catégories suffisamment interprétables.

Une autre limite concerne la sensibilité de K-means à la représentation vectorielle. Les clusters dépendent fortement de la matrice TF-IDF, des choix de lemmatisation, de la liste de mots exclus et des paramètres `min_df` et `max_df`. Une modification de ces choix peut modifier la structure des clusters obtenus, comme cela peut également être le cas avec la NMF. Les résultats doivent donc être compris comme une cartographie exploratoire du corpus, et non comme une classification définitive.

Enfin, comme pour la NMF, la nomination des clusters repose sur une interprétation humaine. Les intitulés attribués aux clusters et aux grandes familles de motifs sont construits à partir des mots les plus représentatifs et de l’observation des segments. Cette étape qualitative est nécessaire pour donner du sens aux résultats, mais elle introduit aussi une part de subjectivité.

4.2.5 Bilan méthodologique

L'ajout d'une classification hiérarchique sur les centres des clusters permet également d'organiser les résultats en grandes familles de motifs. Cette étape rend l'analyse plus lisible, car elle permet de passer de 29 clusters détaillés à cinq ensembles thématiques plus généraux, qui seront interprétés dans la section consacrée aux résultats.

Après la présentation des deux méthodes, la section suivante expose les principaux résultats obtenus, d'abord pour la NMF, puis pour K-means.

5 Résultats

5.1 Topics obtenus avec le NMF

5.1.1 Identification et interprétation des topics

Une fois le modèle entraîné, les mots les plus importants de chaque topic ont été extraits afin de faciliter leur interprétation. Cette étape est essentielle, car le NMF ne produit pas directement des noms de thèmes : elle produit des groupes de mots. L'attribution d'un nom à chaque topic repose donc sur une analyse qualitative des termes les plus représentatifs.

Le tableau suivant présente les dix mots les plus caractéristiques de chaque topic obtenu avec la NMF. Ces mots servent de base à l'interprétation qualitative des thèmes extraits par le modèle.

TABLE 6: Mots caractéristiques des topics obtenus avec la NMF

Topic	Mots caractéristiques
Topic 1	femme, mari, chose, bon, homme, cher, ménage, histoire, vrai, plaisir
Topic 2	travail, peuple, vie, usine, bonheur, justice, ouvrier, œuvre, humanité, terre
Topic 3	arbre, soleil, herbe, eau, ciel, jardin, ombre, terre, feuille, branche
Topic 4	million, bourse, cours, action, universelle, banque, affaire, agent, hausse, titre
Topic 5	abbé, prêtre, curé, église, jardin, trouche, soutane, sous-préfecture, évêque
Topic 6	table, verre, vin, pain, café, eau, maman, assiette, bon, petit
Topic 7	main, œil, mort, bras, sang, tête, corps, face, voix, lèvre
Topic 8	franc, argent, billet, somme, mois, sou, chiffre, pièce, fortune, poche
Topic 9	monsieur, dame, porte, vou, bon, air, voix, tante, main, mot
Topic 10	rue, maison, quartier, trottoir, boutique, boulevard, ville, place, voiture, chaussée
Topic 11	train, gare, heure, machine, chef, voiture, voie, wagon, express, portière
Topic 12	grotte, saint, sœur, malade, miracle, foule, cierge, foi, prêtre, pèlerin
Topic 13	frère, sœur, modèle, petit, écriture, heure, pauvre, fine, lettre, témoin
Topic 14	cardinal, pape, éminence, livre, palais, église, prêtre, don, prélat, romain
Topic 15	école, instituteur, élève, vérité, église, classe, modèle, primaire, enseignement, juif
Topic 16	père, fils, vieux, famille, fille, ferme, terre, paysan, maison, mort
Topic 17	fosse, mineur, ouvrier, camarade, puits, coron, berline, galerie, porion, grève
Topic 18	prussien, soldat, armée, général, route, cheval, corps, canon, capitaine, homme
Topic 19	jeune, fille, homme, oncle, fine, nièce, garçon, mariage, tante, amant
Topic 20	vendeur, rayon, magasin, comptoir, soie, dame, client, vente, bonheur, confection
Topic 21	docteur, médecin, malade, maladie, visite, heure, jour, miracle, cher, jambe
Topic 22	tableau, toile, peintre, peinture, œuvre, atelier, art, artiste, salle, étude
Topic 23	chambre, lit, porte, heure, fenêtre, nuit, escalier, pièce, maison, meuble
Topic 24	enfant, mère, petit, fille, maman, pauvre, nourrice, bon, larme, œil
Topic 25	bel, halle, charcuterie, quenu, boutique, gras, charcutier, marchand, normande, blanc
Topic 26	salon, comte, dame, comtesse, satin, marquis, blanc, rose, femme, petit
Topic 27	empereur, ministre, député, préfet, président, colonel, politique, affaire, lettre, ami
Topic 28	amour, cœur, vie, tendresse, jour, pensée, bonheur, amant, heure, joie
Topic 29	insurgé, barricade, national, ville, fusil, garde, républicain, ouvrier, place, peuple

Chaque topic a ensuite été nommé à partir des mots dominants et de l'observation des segments les plus fortement associés à ce topic. Cette double vérification permet de limiter les erreurs d'interprétation. En effet, certains mots peuvent sembler cohérents isolément, mais prendre un sens différent lorsqu'ils

sont replacés dans les extraits du corpus.

Les topics obtenus couvrent plusieurs dimensions importantes de l'œuvre de Zola. Certains renvoient à des espaces sociaux précis, comme le magasin, la mine, la bourse, le quartier ou le monde ferroviaire. D'autres correspondent à des thèmes plus transversaux, comme la famille, le désir, la maladie, la religion, la pauvreté ou la mort. Cette diversité montre que le NMF permet de faire apparaître à la fois des thèmes sociaux, des motifs narratifs et des univers propres à certains romans.

5.1.2 Nommer les topics

Les topics ont ensuite été nommés manuellement à partir des mots les plus représentatifs et des segments les plus fortement associés. Cette étape constitue une part qualitative importante de l'analyse. Elle permet de transformer les résultats numériques du modèle en catégories interprétables.

TABLE 7: Noms attribués aux topics obtenus avec la NMF

Topic	Nom attribué
Topic 1	Les relations conjugales et la vie domestique
Topic 2	Le travail, le peuple et la justice sociale
Topic 3	La nature et le paysage
Topic 4	La bourse, la finance et les affaires
Topic 5	Le clergé et la paroisse
Topic 6	La table et les repas
Topic 7	Le corps, la souffrance et la mort
Topic 8	L'argent et la fortune
Topic 9	Les conversations et les scènes domestiques
Topic 10	Le quartier et la ville
Topic 11	Le monde ferroviaire
Topic 12	Le miracle, le pèlerinage et la religion
Topic 13	Les liens familiaux, l'écriture et les proches
Topic 14	Le pouvoir religieux
Topic 15	L'école et l'instruction
Topic 16	La famille, la terre et le monde paysan
Topic 17	Le monde ouvrier et la mine
Topic 18	La guerre, les soldats et l'armée
Topic 19	Le désir, le mariage et les relations amoureuses
Topic 20	Le magasin, la vente et les clientes
Topic 21	Le monde médical et la santé
Topic 22	Le monde artistique et la peinture
Topic 23	La chambre, le lit et l'espace intime
Topic 24	L'enfance, la maternité et la pauvreté
Topic 25	Le commerce alimentaire et les halles
Topic 26	Le salon, l'aristocratie et les scènes mondaines
Topic 27	Le pouvoir politique et les affaires publiques
Topic 28	L'amour, le bonheur et les sentiments
Topic 29	L'insurrection et la révolution

Cette étape montre que l'analyse ne repose pas uniquement sur une extraction automatique. Le modèle propose des regroupements de mots, mais leur interprétation dépend d'un travail humain. Les noms attribués aux topics doivent donc être compris comme des catégories d'analyse construites à partir des résultats du modèle, et non comme des vérités objectives produites automatiquement par l'algorithme.

5.2 Nombre de segments associés à chaque topic dominant

Afin d'analyser la répartition des thèmes dans le corpus, un topic dominant a été attribué à chaque segment. Pour cela, les poids de la matrice W ont d'abord été normalisés afin de rendre les contributions des topics comparables entre les

segments. Le topic dominant correspond ensuite au topic dont le poids est le plus élevé pour un segment donné.

La colonne **topic_dominant** indique donc le topic le plus représenté dans chaque paquet de phrases. La colonne **poids_topic** mesure l'intensité de cette association : plus cette valeur est élevée, plus le segment est clairement associé à un topic spécifique. À l'inverse, un poids faible peut signaler un segment plus mixte, contenant plusieurs thèmes ou ne correspondant fortement à aucun topic.

Cette attribution permet de passer d'une simple liste de topics à une analyse plus structurée de leur répartition dans le corpus. Elle rend possible l'étude du nombre de segments associés à chaque topic, du poids moyen des topics dans l'ensemble du corpus et de leur présence selon les romans. Le tableau suivant présente le nombre de segments associés à chaque topic dominant.

TABLE 8: Nombre de segments associés à chaque topic dominant

Topic dominant	Nombre de segments
L'amour, le bonheur et les sentiments	335
La chambre, le lit et l'espace intime	327
Le pouvoir politique et les affaires publiques	266
Le salon, l'aristocratie et les scènes mondaines	266
Le travail, le peuple et la justice sociale	262
La nature et le paysage	229
L'enfance, la maternité et la pauvreté	221
Le corps, la souffrance et la mort	218
La table et les repas	214
Le clergé et la paroisse	210
Le quartier et la ville	205
L'argent et la fortune	187
Le monde ouvrier et la mine	185
La famille, la terre et le monde paysan	180
Le miracle, le pèlerinage et la religion	177
Le désir, le mariage et les relations amoureuses	173
La guerre, les soldats et l'armée	173
L'école et l'instruction	168
Le monde médical et la santé	164
Le commerce alimentaire et les halles	163
Les conversations et les scènes domestiques	162
Le monde artistique et la peinture	141
Le pouvoir religieux	140
Le magasin, la vente et les clientes	136
L'insurrection et la révolution	127
Les liens familiaux, l'écriture et les proches	104
Le monde ferroviaire	94
La bourse, la finance et les affaires	69
Les relations conjugales et la vie domestique	31

La répartition des segments montre que les topics ne sont pas représentés de manière parfaitement équilibrée. Certains thèmes regroupent un nombre important de segments, tandis que d'autres apparaissent de façon plus marginale. Cette variation est attendue dans un corpus littéraire, car tous les motifs thématiques ne sont pas présents avec la même intensité dans l'ensemble des romans.

Les topics les plus représentés correspondent aux thèmes qui structurent fortement le corpus. Les premiers résultats font apparaître des motifs liés aux sentiments, à l'espace intime, aux relations sociales, au pouvoir politique, aux scènes mondaines ou encore au travail. Ces ensembles renvoient à des dimensions récurrentes de l'œuvre de Zola, dans laquelle les expériences individuelles sont souvent articulées à des milieux sociaux, familiaux, économiques ou institutionnels.

À l'inverse, les topics les moins représentés ne doivent pas être considérés comme moins importants sur le plan littéraire. Ils peuvent correspondre à des univers plus localisés, associés à certains romans précis ou à des situations narratives particulières. C'est notamment le cas de thèmes comme la bourse, le monde ferroviaire ou certaines formes de relations domestiques, qui peuvent être fortement présents dans quelques œuvres sans être répartis de manière uniforme dans l'ensemble du corpus.

Cette distribution montre donc que la NMF ne produit pas seulement une liste de thèmes interprétables : elle permet aussi d'évaluer leur poids relatif dans le corpus. Le nombre de segments associés à chaque topic donne une première indication de l'importance quantitative des thèmes extraits. Cette mesure doit toutefois être interprétée avec prudence : un topic fréquent n'est pas nécessairement plus important sur le plan littéraire, mais il est plus présent lexicalement dans les segments analysés.

Enfin, cette attribution des topics dominants peut servir de base à des analyses complémentaires. Elle permet notamment d'étudier la distribution des topics par œuvre, de comparer les romans entre eux, ou encore d'appliquer ultérieurement un détecteur de motifs aux segments associés à chaque topic afin d'identifier les motifs narratifs les plus caractéristiques de chaque thème.

5.3 Clusters obtenus avec K-means

5.3.1 Extraction des mots caractéristiques des clusters

Une fois le modèle entraîné, les centres des clusters ont été analysés afin d'identifier les termes les plus représentatifs de chaque groupe. Dans K-means, chaque cluster est représenté par un centroïde, c'est-à-dire un point moyen dans l'espace vectoriel. Les termes les plus fortement associés à ce centroïde permettent de comprendre le contenu thématique du cluster.

Cette étape est comparable à l'extraction des mots dominants dans la NMF. Elle permet d'associer chaque cluster à un ensemble de termes caractéristiques. Cependant, l'interprétation est légèrement différente : dans la NMF, les mots sont associés à un topic latent ; dans K-means, ils décrivent le centre lexical d'un groupe de segments. Autrement dit, les mots obtenus indiquent ce qui rapproche

les segments d'un même cluster.

TABLE 9: Mots caractéristiques des clusters obtenus avec K-means

Cluster	Mots caractéristiques
Cluster 1	verre, petit, table, maman, coup, femme, vin, eau, tête, homme
Cluster 2	instituteur, école, enfant, vérité, élève, petit, église, père, classe, bon
Cluster 3	salon, dame, femme, monsieur, petit, blanc, satin, homme, jeune, rose
Cluster 4	chambre, porte, lit, monsieur, heure, femme, petit, maison, escalier, fenêtre
Cluster 5	enfant, femme, nourrice, petit, usine, constance, fille, mari, monsieur, cher
Cluster 6	mère, fille, petit, enfant, père, femme, fils, bon, jeune, œil
Cluster 7	train, gare, chef, machine, voie, heure, express, mécanicien, tunnel, voyageur
Cluster 8	amour, cœur, vie, jeune, enfant, femme, fille, jour, homme, tendresse
Cluster 9	comte, comtesse, monsieur, scène, loge, femme, prulière, homme, théâtre, dame
Cluster 10	abbé, prêtre, curé, monsieur, église, bon, tête, petit, frère, enfant
Cluster 11	arbre, soleil, herbe, ciel, eau, ombre, jardin, blanc, haut, terre
Cluster 12	grotte, saint, miracle, cierge, prêtre, malade, foule, foi, père, église
Cluster 13	docteur, médecin, monsieur, enfant, mère, petit, malade, heure, œil, lit
Cluster 14	sœur, malade, hyacinthe, wagon, saint, train, petit, compartiment, pèlerin, grotte
Cluster 15	insurgé, ville, national, fusil, barricade, républicain, homme, garde, ouvrier, rue
Cluster 16	rue, boutique, trottoir, petit, quartier, maison, femme, bel, halle, heure
Cluster 17	femme, jeune, amant, chambre, main, pensée, œil, bras, nuit, homme
Cluster 18	empereur, ministre, monsieur, député, colonel, homme, affaire, préfet, gouvernement, ami
Cluster 19	travail, vie, enfant, terre, petit, usine, ouvrier, peuple, œuvre, homme
Cluster 20	bourse, million, franc, action, cours, banque, universelle, monsieur, hausse, argent
Cluster 21	franc, argent, monsieur, femme, homme, jeune, jour, billet, somme, bon
Cluster 22	monsieur, dame, femme, petit, porte, bon, fille, air, homme, chambre
Cluster 23	tableau, peintre, toile, peinture, œuvre, art, atelier, femme, artiste, salon
Cluster 24	fosse, mineur, coron, camarade, berline, homme, ouvrier, puits, grève, porion
Cluster 25	vendeur, rayon, magasin, comptoir, dame, soie, vente, client, bonheur, franc
Cluster 26	prussien, soldat, armée, général, route, homme, cheval, capitaine, corps, canon
Cluster 27	cardinal, pape, palais, éminence, livre, prêtre, monde, église, peuple, prélat
Cluster 28	frère, modèle, petit, père, vérité, président, homme, crime, justice, écriture
Cluster 29	père, terre, vieux, petit, coup, bon, vache, homme, paysan, bête

Cette extraction permet de vérifier la cohérence interne des clusters. Lorsqu'un cluster rassemble des mots appartenant au même champ lexical, il devient plus facilement interprétable. À l'inverse, un cluster contenant des mots trop dispersés ou peu cohérents peut indiquer un regroupement moins stable ou plus

difficile à nommer.

5.3.2 Nomination des clusters

Les clusters ont ensuite été nommés manuellement à partir des mots les plus représentatifs et de l’observation des segments associés. Cette étape est indispensable, car K-means ne produit pas directement des intitulés interprétables. Comme pour la NMF, le passage du résultat numérique à l’interprétation thématique repose donc sur une lecture qualitative.

TABLE 10: Noms attribués aux clusters obtenus avec K-means

Cluster	Nom attribué
Cluster 1	La table, les repas et les boissons
Cluster 2	L’école, les élèves et l’instruction
Cluster 3	Le salon, l’aristocratie et les apparences
Cluster 4	La chambre, le lit et l’espace domestique
Cluster 5	L’enfance, la maternité et la pauvreté
Cluster 6	La mère, les enfants et la famille
Cluster 7	Le monde ferroviaire
Cluster 8	L’amour, les sentiments et la jeunesse
Cluster 9	Le théâtre, la loge et les scènes mondaines
Cluster 10	Le clergé et la paroisse
Cluster 11	La nature et le paysage
Cluster 12	Le miracle, le pèlerinage et la religion
Cluster 13	Le monde médical et la santé
Cluster 14	Le pèlerinage, la maladie et le voyage
Cluster 15	L’insurrection et la révolution
Cluster 16	Le quartier, la rue et la ville
Cluster 17	Le désir, le corps et les relations amoureuses
Cluster 18	Le pouvoir politique et les affaires publiques
Cluster 19	Le travail, le peuple et le monde ouvrier
Cluster 20	La bourse, la finance et les affaires
Cluster 21	L’argent du quotidien
Cluster 22	Les conversations et les scènes domestiques
Cluster 23	Le monde artistique et la peinture
Cluster 24	La mine, les ouvriers et la grève
Cluster 25	Le magasin, la vente et les clientes
Cluster 26	La guerre, les soldats et l’armée
Cluster 27	Le pouvoir religieux
Cluster 28	Les liens familiaux, l’écriture et la justice
Cluster 29	La terre, les animaux et le monde paysan

Les intitulés obtenus montrent que les clusters couvrent des dimensions proches de celles observées avec la NMF. On retrouve par exemple des en-

sembles liés au travail, à la mine, à la finance, à la religion, à la famille, au monde domestique, à la guerre ou encore aux espaces urbains.

Cependant, les clusters K-means ne doivent pas être interprétés comme des catégories fixes ou naturelles. Ils résultent d'un regroupement algorithmique fondé sur la proximité lexicale des segments. Leur nomination repose donc sur un choix interprétatif, à partir des mots les plus représentatifs et des extraits textuels associés.

5.3.3 Regroupement hiérarchique des clusters

Afin de compléter l'analyse des clusters obtenus avec K-means, une classification ascendante hiérarchique a été appliquée aux centroïdes des 29 clusters. Cette étape permet d'examiner les proximités entre clusters et de regrouper ceux qui présentent des profils lexicaux similaires. Elle offre ainsi une lecture plus synthétique de la structure thématique du corpus, en passant d'une analyse détaillée cluster par cluster à une organisation en grandes familles de motifs.

La méthode de Ward a été retenue pour construire cette hiérarchie. Elle consiste à fusionner progressivement les clusters en minimisant l'augmentation de la variance interne à chaque regroupement. Le dendrogramme obtenu permet de visualiser les distances entre clusters et d'identifier les principaux rapprochements thématiques.




FIGURE 4 – Dendrogramme de la classification hiérarchique des clusters K-means

Dans cette analyse, le seuil de distance a été fixé à 0,40 afin de découper l'arbre hiérarchique en grandes familles de motifs. Ce regroupement rend les résultats plus lisibles : les 29 clusters initiaux peuvent être interprétés non seulement individuellement, mais aussi comme des ensembles thématiques plus larges. Cette organisation facilite ensuite la comparaison entre les motifs dominants du corpus et leur répartition dans les romans de Zola.

5.3.4 Création des grandes familles de motifs

À partir du dendrogramme, les clusters ont été regroupés en cinq grandes familles de motifs. Cette opération permet de simplifier l'analyse et de faire apparaître les grandes zones thématiques du corpus.




FIGURE 5 – Regroupement des clusters K-means en grandes familles de motifs

Les groupes obtenus ont ensuite été nommés manuellement, en fonction des clusters qu'ils rassemblent. Le tableau suivant présente la composition de chaque grande famille de motifs.

TABLE 11: Composition des grandes familles de motifs issues des clusters K-means

Groupe	Clusters associés
Groupe 1	Cluster 12 : Le miracle, le pèlerinage et la religion ; Cluster 14 : Le pèlerinage, la maladie et le voyage.
Groupe 2	Cluster 2 : L'école, les élèves et l'instruction ; Cluster 10 : Le clergé et la paroisse ; Cluster 27 : Le pouvoir religieux ; Cluster 28 : Les liens familiaux, l'écriture et la justice.
Groupe 3	Cluster 9 : Le théâtre, la loge et les scènes mondaines ; Cluster 18 : Le pouvoir politique et les affaires publiques ; Cluster 20 : La bourse, la finance et les affaires ; Cluster 21 : L'argent du quotidien ; Cluster 22 : Les conversations et les scènes domestiques ; Cluster 25 : Le magasin, la vente et les clientes.
Groupe 4	Cluster 15 : L'insurrection et la révolution ; Cluster 26 : La guerre, les soldats et l'armée.
Groupe 5	Cluster 1 : La table, les repas et les boissons ; Cluster 3 : Le salon, l'aristocratie et les apparences ; Cluster 4 : La chambre, le lit et l'espace domestique ; Cluster 5 : L'enfance, la maternité et la pauvreté ; Cluster 6 : La mère, les enfants et la famille ; Cluster 7 : Le monde ferroviaire ; Cluster 8 : L'amour, les sentiments et la jeunesse ; Cluster 11 : La nature et le paysage ; Cluster 13 : Le monde médical et la santé ; Cluster 16 : Le quartier, la rue et la ville ; Cluster 17 : Le désir, le corps et les relations amoureuses ; Cluster 19 : Le travail, le peuple et le monde ouvrier ; Cluster 23 : Le monde artistique et la peinture ; Cluster 24 : La mine, les ouvriers et la grève ; Cluster 29 : La terre, les animaux et le monde paysan.

Ces grandes familles permettent d'obtenir une lecture plus synthétique des résultats. La première famille regroupe les motifs liés au miracle, au pèlerinage et à la religion. La deuxième rassemble des clusters associés aux formes d'encadrement social, religieux, scolaire et familial. La troisième renvoie davantage aux espaces sociaux, économiques et mondains, en regroupant notamment la finance, le commerce, le théâtre et les conversations domestiques. La quatrième famille réunit les motifs du conflit collectif, de l'insurrection et de la guerre. Enfin, la cinquième regroupe un ensemble plus large de motifs liés à la vie quotidienne, aux espaces sociaux, au travail, à la famille, à la nature et aux expériences individuelles.

Cette structuration est particulièrement utile pour l'analyse littéraire, car elle permet de passer d'une liste de clusters nombreux à une organisation thématique plus lisible. Elle montre aussi que les motifs extraits par K-means ne sont pas isolés, mais peuvent être regroupés en ensembles plus larges correspondant à des dimensions importantes de l'œuvre de Zola.

5.3.5 Attribution des grandes familles aux segments

Une fois les groupes hiérarchiques définis, chaque segment du corpus a reçu une étiquette correspondant à la grande famille de motifs associée à son cluster¹⁵. Cette opération permet d’analyser non seulement les clusters détaillés, mais aussi les grandes catégories thématiques dans lesquelles ils s’inscrivent.




FIGURE 6 – Noms attribués aux grandes familles de motifs

Cette étape permet de relier chaque paquet de phrases à deux niveaux d’analyse. Le premier niveau est le cluster K-means, qui fournit une catégorie thématique fine. Le second niveau est le groupe CAH, qui fournit une catégorie plus générale. Cette double échelle d’interprétation est utile, car elle permet d’adapter le niveau de détail selon les besoins de l’analyse : on peut étudier les motifs précis, ou bien observer les grandes tendances du corpus.

5.3.6 Analyse de la répartition des clusters

Après la nomination des clusters et des grandes familles, plusieurs visualisations ont été produites afin d’étudier leur répartition dans le corpus. La première consiste à compter le nombre de segments associés à chaque grande famille de motifs.




FIGURE 7 – Distribution des grandes familles de motifs dans le corpus

15. Voir code en annexe

Cette visualisation permet d'identifier les grandes familles les plus représentées dans l'ensemble du corpus. Elle donne une lecture globale de l'organisation thématique des segments. Une famille très représentée indique qu'un ensemble de motifs revient fréquemment dans les romans, tandis qu'une famille moins présente peut correspondre à un thème plus spécifique, associé à certains romans ou à certaines situations narratives.

Une seconde visualisation a été produite à l'échelle des clusters détaillés.




FIGURE 8 – Distribution des clusters K-means dans le corpus

Cette représentation permet de voir quels clusters sont les plus fréquents dans le corpus. Elle est plus précise que l'analyse par grandes familles, car elle distingue les motifs thématiques particuliers. Elle permet par exemple d'observer séparément les clusters associés à la mine, à la finance, à la religion, à la famille ou au monde domestique.

6 Comparaison des deux méthodes

6.1 Différences entre NMF et K-means

Contrairement à la NMF, qui attribue à chaque segment un poids pour chacun des topics, K-means attribue chaque segment à un seul cluster. Cette différence est importante : la NMF autorise une lecture plus graduelle des thèmes,

tandis que K-means produit une classification plus nette. Un segment appartient à un cluster principal, même s’il peut contenir plusieurs motifs thématiques.

La NMF permet donc d’observer la présence simultanée de plusieurs thèmes dans un même segment, alors que K-means propose une lecture plus catégorielle du corpus. Les deux méthodes ne répondent donc pas exactement au même objectif : la première met en évidence des topics latents, tandis que la seconde regroupe les segments selon leur proximité lexicale.

6.2 Convergences thématiques

Les intitulés obtenus montrent que les clusters couvrent des dimensions proches de celles observées avec la NMF. On retrouve par exemple des ensembles liés au travail, à la mine, à la finance, à la religion, à la famille, au monde domestique, à la guerre ou encore aux espaces urbains. Cette convergence entre les deux méthodes est intéressante, car elle indique que certains thèmes apparaissent de manière stable dans le corpus, indépendamment de la méthode utilisée.



FIGURE 9 – Heatmap des poids des mots dans les topics NMF




FIGURE 10 – Heatmap des poids des mots dans les clusters K-means

La méthode K-means permet ainsi de compléter l’analyse réalisée avec la NMF. Elle offre une autre manière d’observer les régularités thématiques du corpus, non plus sous la forme de topics latents, mais sous la forme de groupes de segments lexicalement proches. Cette approche confirme plusieurs motifs déjà observés avec la NMF, notamment autour du travail, de la religion, de la famille, de l’argent, de la guerre, de la mine, du commerce ou de l’espace domestique.

6.3 Distribution des thèmes par œuvre

Afin d’observer la présence des clusters dans chaque roman, une table croisée a été construite entre les fichiers du corpus et les clusters thématiques. La normalisation par ligne permet d’obtenir, pour chaque œuvre, la proportion de segments associés à chaque cluster.

Cette analyse est importante, car elle permet de relier les clusters aux romans. Certains clusters peuvent être très transversaux et apparaître dans de nombreuses œuvres, tandis que d’autres peuvent être fortement associés à un roman précis. Par exemple, un cluster lié à la mine peut être particulièrement représenté dans *Germinal*, tandis qu’un cluster lié à la finance peut être plus présent dans *L’Argent*. De la même manière, les clusters associés au commerce peuvent être importants dans *Au Bonheur des dames*, et ceux liés à la guerre dans *La Débâcle*.

Une analyse similaire a été réalisée au niveau des grandes familles de motifs. Cette seconde visualisation offre une lecture plus synthétique. Elle permet de comparer les romans selon les grandes familles de motifs qui les structurent. Cette approche est particulièrement utile pour repérer des oppositions ou des proximités entre les œuvres : certains romans peuvent être dominés par des motifs de vie quotidienne, tandis que d’autres accordent plus de place aux ins-

titutions, à la religion, à la guerre ou aux conflits sociaux.

6.4 Apport de la double approche

Ainsi, K-means ne remplace pas la NMF, mais il constitue un complément méthodologique utile. En croisant les résultats des deux méthodes, il devient possible de distinguer les thèmes particulièrement stables de ceux qui dépendent davantage du modèle utilisé. Cette double approche renforce donc la solidité de l'analyse, tout en conservant une part d'interprétation qualitative indispensable dans l'étude d'un corpus littéraire.

7 Conclusion

Cette étude avait pour objectif d'identifier des structures thématiques récurrentes dans l'œuvre romanesque de Zola à partir de méthodes non supervisées. Le corpus a d'abord été nettoyé, segmenté en paquets de phrases, puis lemmatisé afin de produire des unités textuelles comparables et exploitables par les modèles.

L'application de la NMF a permis de faire apparaître des topics interprétables, associés à des dimensions importantes de l'univers zolien : le travail, la mine, la religion, la famille, l'argent, la guerre, le commerce, la ville ou encore l'espace domestique. Le recours à K-means a ensuite permis de regrouper les segments selon leur proximité lexicale et d'observer des familles de motifs complémentaires.

La comparaison des deux méthodes montre que certains ensembles thématiques apparaissent de manière stable, malgré des fonctionnements algorithmiques différents. La NMF offre une lecture plus graduelle des thèmes, tandis que K-means produit une classification plus nette des segments. Leur combinaison permet donc de renforcer l'analyse en croisant deux formes de structuration du corpus.

Ces résultats doivent toutefois être interprétés avec prudence. Ils dépendent des choix de nettoyage, de lemmatisation, de segmentation, de vectorisation et du nombre de topics ou de clusters retenus. L'analyse proposée ne remplace donc pas une lecture littéraire des textes, mais elle fournit un outil exploratoire permettant de repérer des régularités lexicales et thématiques à l'échelle d'un corpus volumineux.

A Annexe technique : code de l'analyse

Cette annexe regroupe les principaux blocs de code utilisés pour préparer le corpus, lemmatiser les textes et appliquer les méthodes de modélisation thématique. Elle permet de conserver le corps de l'article principal plus lisible.

A.1 Segmentation du corpus

```

1 def segmenter_en_paquets(texte, taille_paquet=40):
2     # Segmente le texte en paquets de phrases
3     phrases = texte.splitlines()
4     phrases = [p.strip() for p in phrases if p.strip()]
5     paquets = []
6
7     for i in range(0, len(phrases), taille_paquet):
8         paquet = " ".join(phrases[i:i+taille_paquet])
9         paquets.append(paquet)
10    return paquets
11
12 rows = []
13
14 for _, row in df.iterrows():
15     # Iteration sur chaque ligne du DataFrame
16     paquets = segmenter_en_paquets(row["texte_brut"])
17
18     for idx, paquet in enumerate(paquets):
19         rows.append({
20             "nom_fichier": row["nom_fichier"],
21             "id_paquet": idx,
22             "phrases_paquet": paquet
23         })
24
25 df_phrases = pd.DataFrame(rows)

```

Listing 1 – Code de segmentation du texte en paquets de phrases

A.2 Lemmatisation et filtrage lexical

```

1 nlp = spacy.load("fr_core_news_lg", disable=["ner", "parser"])
2 # Chargement du modele de langue francaise de spaCy.
3 # Les composants de reconnaissance des entites nommees et d'analyse
4 # syntactique sont desactives afin d'accelerer le traitement.
5
6 nlp.max_length = 2_000_000
7 # Augmentation de la longueur maximale des textes traites par spaCy.
8 # Cette valeur est ajustable selon la taille des textes et la memoire
9 # disponible sur la machine.

```

Listing 2 – Importation du modèle français de spaCy

```

1 stop_word = {
2     "je", "tu", "il", "elle", "ils", "elles", "nous", "vous",
3     "me", "te", "se", "moi", "toi", "eux", "leur", "leurs",
4     "ses", "mon", "ton", "son", "notre", "votre", "cette",
5     "\u00e7a", "si", "m\u00eame", "o\u00f9", "dont", "sans",
6     "quand", "bien", "l\u00e0", "sous", "\u00eatre", "avoir",
7     "faire", "dire", "aller", "voir", "pouvoir", "demander",
8     "prendre", "mettre", "parler", "devoir", "trouver", "donner",
9     "comprendre", "savoir", "vouloir", "venir", "est", "ai",
10    "as", "avez", "ont", "avaient", "\u00etaient", "deux",
11    "cent", "cents", "cinq", "dix", "vingt", "mille",
12    "mme", "madame", "monsieur", "m", "mr", "mlle",
13    "nana", "gervaise", "louis", "lazare", "etienne", "claud",
14    "suzanne", "mouret", "rougon", "macquart", "saccard",
15    "lacroix", "renn\u00e9", "silv\u00e8re", "revert\u00e9",
16    "mahoudeau", "ren\u00e9", "xiii", "silv\u00e8re", "miette",
17    "boccanera", "deberl", "daigremont", "lorilleu", "maheude",
18    "cas", "f\u00e9licit\u00e9", "coupeau", "granou", "granoux",
19    "gagni\u00e8re", "gagniere"
20 }

```

Listing 3 – Liste de stop words personnalisée

```

1
2 def nettoyer_texte(texte):
3     doc = nlp(texte)
4     tokens = []
5
6     for token in doc:
7         lemme = token.lemma_.lower()
8
9         if (
10             not token.is_stop
11             and not token.is_punct
12             and not token.like_num
13             and not token.is_space
14             and token.pos_ in {"NOUN", "ADJ"}
15             and len(lemme) > 2
16             and lemme not in stop_word
17         ):
18             tokens.append(lemme)
19
20     return " ".join(tokens)

```

Listing 4 – Fonction de lemmatisation avec exclusion de mots spécifiques

A.3 Vectorisation TF-IDF

Le vectoriseur utilisé est défini de la manière suivante :

```

1 vectorizer = TfidfVectorizer(
2     min_df=3,
3     max_df=0.8
4 )
5 X = vectorizer.fit_transform(df["phrases_lemm"])

```

B Trouver un K optimal pour la modélisation thématique

```
1 errors = []
2 k_values = range(20, 40)
3
4 for k in k_values:
5     nmf = NMF(
6         n_components=k,
7         random_state=42,
8         init="nndsvda",
9         max_iter=500
10    )
11
12    nmf.fit(X)
13    errors.append(nmf.reconstruction_err_)
```

Listing 6 – Recherche du nombre de topics par la méthode du coude

B.1 Modélisation par NMF

Le modèle final est défini de la manière suivante :

```
1 nmf = NMF(
2     n_components=29,
3     random_state=42,
4     init="nndsvda",
5     solver="cd",
6     max_iter=1000
7 )
8
9 W = nmf.fit_transform(X)
10 H = nmf.components_
```

Listing 7 – Entraînement du modèle NMF final

```
1 W_norm = W / W.sum(axis=1, keepdims=True)
2
3 df["topic_dominant"] = W_norm.argmax(axis=1)
4 df["poids_topic"] = W_norm.max(axis=1)
```

Listing 8 – Attribution du topic dominant à chaque segment

B.2 Clustering par K-means

```
1 scores = []
2
3 for k in range(2, 41):
4     model = KMeans(
5         n_clusters=k,
6         random_state=42,
7         n_init=10
8     )
9     labels = model.fit_predict(X)
10    score = silhouette_score(X, labels)
11    scores.append((k, score))
12
13 scores_df = pd.DataFrame(scores, columns=["k", "silhouette"])
```

Listing 9 – Évaluation du nombre de clusters par score de silhouette

```
1 plt.figure(figsize=(10, 6))
2 plt.xticks(range(2, 41))
3
4 plt.plot(scores_df["k"], scores_df["silhouette"], marker="o")
5
6 plt.xlabel("Nombre de clusters k")
7 plt.ylabel("Score de silhouette")
8 plt.title("Score de silhouette selon le nombre de clusters")
9
10 plt.show()
```

Listing 10 – Visualisation du score de silhouette selon le nombre de clusters

```
1 kmeans = KMeans(
2     n_clusters=29,
3     random_state=42,
4     n_init=10
5 )
6 df["cluster"] = kmeans.fit_predict(X) + 1
```

Listing 11 – Entraînement du modèle K-means final

B.3 Affichage resultats

```
1 def afficher_topics(model, feature_names, n_top_words=10):
2     for topic_idx, topic in enumerate(model.components_):
3         top_words = [
4             feature_names[i]
5             for i in topic.argsort()[: -n_top_words - 1 : -1]
6         ]
7         print(f"Topic {topic_idx+1} : {' | '.join(top_words)}")
8
9 feature_names = vectorizer.get_feature_names_out()
10 afficher_topics(nmf, feature_names)
```

Listing 12 – Affichage des mots les plus importants par topic

```

1 terms = vectorizer.get_feature_names_out()
2 centres = kmeans.cluster_centers_
3
4 for i, centre in enumerate(centres):
5     top_indices = centre.argsort()[::-1][:10]
6     mots = [terms[j] for j in top_indices]
7     print(f"Cluster {i+1} :", " | ".join(mots))

```

Listing 13 – Extraction des mots les plus représentatifs par cluster

```

1 noms_groupes_cah = {
2     1: "Religion locale et autorite clericale",
3     2: "Guerre, insurrection et conflit politique",
4     3: "Institutions, croyances et encadrement social",
5     4: "Argent, dettes et circulation financiere",
6     5: "Vie quotidienne, espaces sociaux et experiences individuelles"
7 }
8
9 df_groupes["nom_groupe_cah"] = df_groupes["groupe_cah"].map(
10     noms_groupes_cah
11 )

```

Listing 14 – Nomination des grandes familles de motifs

```

1 cluster_vers_groupe = dict(
2     zip(df_groupes["cluster"], df_groupes["groupe_cah"])
3 )
4
5 df["groupe_cah"] = df["cluster"].map(cluster_vers_groupe)
6 df["nom_groupe_cah"] = df["groupe_cah"].map(noms_groupes_cah)

```

Listing 15 – Attribution des groupes CAH aux segments du corpus

B.4 Visualisations

```

1 Z = linkage(centres, method="ward")
2
3 dendrogram(
4     Z,
5     labels=[f"Cluster {i+1}" for i in range(kmeans.n_clusters)],
6     orientation="right",
7     color_threshold=0.40
8 )
9
10 plt.axvline(x=0.40, color="red", linestyle="--")
11
12 plt.title("CAH sur les clusters K-means")
13 plt.xlabel("Distance")
14 plt.show()

```

Listing 16 – Classification hiérarchique sur les centres des clusters


```

1 groupes_cah = fcluster(Z, t=0.40, criterion="distance")
2
3 df_groupes = pd.DataFrame({
4     "cluster": range(1, kmeans.n_clusters + 1),
5     "groupe_cah": groupes_cah
6 })
7
8 df_groupes["nom_cluster"] = df_groupes["cluster"].map(
9     noms_clusters_kmeans
10 )

```

Listing 17 – Création des groupes CAH à partir des clusters K-means

```

1 counts = df["nom_groupe_cah"].value_counts().sort_values()
2
3 plt.figure(figsize=(10, 6))
4 counts.plot(kind="barh")
5
6 plt.title("Nombre de segments par grande famille de motifs")
7 plt.xlabel("Nombre de segments")
8 plt.ylabel("Groupe CAH")
9 plt.show()

```

Listing 18 – Nombre de segments par grande famille de motifs